

3. 回帰分析の基礎

honocat

2025-12-28

```
HR <- read_csv('data/hr-data.csv')
glimpse(HR)
```

```
Rows: 8,803
Columns: 22
$ year      <dbl> 1996, 1996, 1996, 1996, 1996, 1996, 1996, 1996, 1996, ~
$ ku        <chr> "aichi", "aichi", "aichi", "aichi", "aichi", "aichi", "aich~
$ kun       <dbl> 1, 1, 1, 1, 1, 1, 2, 2, 2, 2, 2, 2, 2, 3, 3, 3, 3, 3, ~
$ status     <chr> "現職", "元職", "現職", "新人", "新人", "新人", "現職", "元
職", "新人", ~
$ name       <chr> "KAWAMURA, TAKASHI", "IMAEDA, NORIO", "SATO, TAISUKE", "IWA~
$ party      <chr> "NFP", "LDP", "DPJ", "JCP", "others", "kokuminto", "independen~
$ party_code <dbl> 8, 1, 3, 2, 100, 22, 99, 8, 1, 3, 2, 10, 100, 99, 22, 8, 1, ~
$ previous    <dbl> 2, 3, 2, 0, 0, 0, 1, 1, 0, 0, 0, 0, 0, 1, 3, 1, 0, 0, ~
$ wl         <chr> "当選", "落選", "落選", "落選", "落選", "落選", "當選", "落
選", "復活當選"
$ voteshare   <dbl> 40.0, 25.7, 20.1, 13.3, 0.4, 0.3, 0.2, 32.9, 26.4, 25.7, 12~
$ age         <dbl> 47, 72, 53, 43, 51, 51, 45, 51, 71, 30, 31, 44, 61, 47, 43, ~
$ nocand      <dbl> 7, 7, 7, 7, 7, 7, 8, 8, 8, 8, 8, 8, 8, 7, 7, 7, 7, 7, ~
$ rank        <dbl> 1, 2, 3, 4, 5, 6, 7, 1, 2, 3, 4, 5, 6, 7, 8, 1, 2, 3, 4, 5, ~
$ vote        <dbl> 66876, 42969, 33503, 22209, 616, 566, 312, 56101, 44938, 43~
$ eligible    <dbl> 346774, 346774, 346774, 346774, 346774, 346774, 346774, 338~
$ turnout     <dbl> 49.2, 49.2, 49.2, 49.2, 49.2, 49.2, 51.8, 51.8, 51.8, 51.8, ~
$ exp         <dbl> 9828097, 9311555, 9231284, 2177203, NA, NA, NA, 12940178, 1~
$ expm        <dbl> 9.828097, 9.311555, 9.231284, 2.177203, NA, NA, NA, 12.9401~
$ vs          <dbl> 0.400, 0.257, 0.201, 0.133, 0.004, 0.003, 0.002, 0.329, 0.2~
$ exppv       <dbl> 28.341505, 26.851941, 26.620462, 6.278449, NA, NA, NA, 38.2~
$ smd         <chr> "当選", "落選", "落選", "落選", "落選", "落選", "當選", "落
選", "落選", ~
$ party_jpn   <chr> "新進党", "自民党", "民主党", "共産党", "その他", "国民党", "無所属", "
```

新進党", "自民~

衆議院議員経験があることを表すダミー変数と、選挙費用を 100 万($1e6 = 10^6$)円単位で測定する変数を作る。

```
HR <- HR |>
  mutate(experience = as.numeric(status == '現職' | status == '元職'),
        expm      = exp / 1e6)
```

次に、データから 2009 年の結果だけ抜き出し、HR09 として保存する。

```
HR09 <- HR |>
  filter(year == 2009)
```

R で線形回帰分析を行う

説明変数が二値しか取らない(ダミー変数)とき(モデル 1)

得票率(結果変数)を議員経験(説明変数)で説明するモデルを考える。議員経験は、現職または元職の候補者なら 1、そうでなければ 0 を取る二値(binary)変数(ダミー変数)である。このモデルを式で表すと、

$$\text{得票率} = \beta_1 + \beta_2 \cdot \text{議員経験}_i + e_i$$

と、なる。

R では、`lm()` で回帰式を推定することができる。

```
fit_1 <- lm(voteshare ~ experience, data = HR09)
```

基本的には結果は、`summary()` で。

```
summary(fit_1)
```

Call:

```
lm(formula = voteshare ~ experience, data = HR09)
```

Residuals:

Min	1Q	Median	3Q	Max
-43.867	-12.072	-5.567	8.583	52.123

```

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 13.8772    0.6203   22.37 <2e-16 ***
experience  30.9898    0.9783   31.68 <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 16.19 on 1137 degrees of freedom
Multiple R-squared:  0.4688, Adjusted R-squared:  0.4684
F-statistic: 1004 on 1 and 1137 DF, p-value: < 2.2e-16

```

`broom::tidy()` も使える。

```
broom::tidy(fit_1)
```

```

# A tibble: 2 x 5
  term      estimate std.error statistic  p.value
  <chr>     <dbl>     <dbl>     <dbl>     <dbl>
1 (Intercept) 13.9      0.620    22.4 3.78e- 92
2 experience  31.0      0.978    31.7 2.18e-158

```

この出力の `estimate` の列の係数の推定値(coefficient estimates)が示される。これにより、 $\hat{\beta}_1 = 13.88$, $\hat{\beta}_2 = 30.99$ が得られた。したがって、

$$\widehat{\text{得票率}} = 13.88 + 30.99 \cdot \text{議員経験}$$

と、なる。

傾きの値を、分散と共に分散を利用して求めてみる。分散は `var()`、共分散は `cov()` で計算できる。

```
with(HR09, cov(voteshare, experience) / var(experience))
```

```
[1] 30.98979
```

`lm()` で求めた傾きと一致する。

次に、行列計算で回帰係数を求める。結果変数の N 次元列ベクトルを $N \times 1$ 行列として用意する。

```
y <- matrix(HR09$voteshare, ncol = 1)
```

行列計算は、第 1 列がすべて 1、第 2 列が議員経験なので、

```
N <- length(y)
X <- matrix(c(rep(1, N), HR09$experience), ncol = 2)
```

行列の掛け算は `%*%`、転置は `t()`、逆行列は `slove()` で求められるので、回帰係数 `b_hat` は、


```
b_hat <- t(X) %*% X |>
  solve() %*% t(X) %*% y
b_hat
```

```
[,1]
[1,] 13.87724
[2,] 30.98979
```

`lm()` を使った場合と同じ結果が得られる。

この結果を図示する。

```
p1 <- ggplot(HR09, aes(x = experience, y = voteshare)) +
  scale_x_continuous(breaks = c(0, 1)) +
  geom_jitter(position = position_jitter(width = 0.05), size = 1) +
  geom_smooth(method = 'lm', se = FALSE) +
  labs(x = '議員経験', y = '得票率(%)')
plot(p1 + ggtitle('得票率と議員経験の関係'))
```



この図に推定の不確実性を示すには、`geom_smooth(method = 'lm', se = TRUE)` とすればよい。

この直線の切片である、13.88 は、議員経験がない候補者の平均得票率(予測得票率)である。予測値の式の「議

員経験」に 0 を代入すれば、これは明らかである。議員経験がある候補者の平均得票率(予測得票率)は「議員経験」に 1 を代入することで得られる。代入してみると、 $13.88 + 30.99 \cdot 1 = 44.87$ となる。

議員経験ごとに平均得票率を求め、予測値と一致するか確かめる。

```
HR09 |>
  group_by(experience) |>
  summarise(voteshare = mean(voteshare),
             .groups    = 'drop')
```

```
# A tibble: 2 x 2
  experience voteshare
  <dbl>      <dbl>
1 0          13.9
2 1          44.9
```

このように、予測値は説明変数の値を与えられたときの、結果変数の平均値であることがわかる。

説明変数が連続値をとるとき(モデル 2)

同様に、得票率を選挙費用(測定単位：100 万円)で説明するモデルは、次のように推定できる。

```
fit_2 <- lm(voteshare ~ expm, data = HR09)
broom::tidy(fit_2)
```

```
# A tibble: 2 x 5
  term       estimate std.error statistic   p.value
  <chr>     <dbl>     <dbl>     <dbl>     <dbl>
1 (Intercept)  7.74     0.757    10.2  1.61e- 23
2 expm        3.07     0.0958   32.1  1.14e-160
```

傾きの値を、分散と共に分散を利用して求める。`expm` には欠測値があるので、除外する。

```
HR09 |>
  filter(!is.na(expm)) |>
  with(cov(voteshare, expm) / var(expm))
```


```
[1] 3.071721
```

回帰直線を図示する。

```

p2 <- ggplot(HR09, aes(x = expm, y = voteshare)) +
  geom_point(size = 1) +
  geom_smooth(method = 'lm', se = FALSE) +
  labs(x = '選挙費用(100万円)', y = '得票率(%)')
plot(p2 + ggtitle('得票率と選挙費用の関係'))

```



95% 信頼区間を加える。

```

p2_ci95 <- p2 + geom_smooth(method = 'lm')
plot(p2_ci95 + ggtitle('得票率と選挙費用の関係'))

```

